


YAPAY ZEKÂ TABANLI EMG SİNYALLERİ İLE

El Hareketi Sınıflandırma Analizi

Yöntemler · Öznitelikler · Parametreler · Altı Modelin Karşılaştırması



Burak Talha Güçlü | Yüksek Lisans Tez Çalışması

Sunum Akışı

1 Problem, EMG ve motivasyon

3 Sinyal ön işleme

5 Altı model: parametreler & gerekçeler

7 Sonuçlar ve detaylı karşılaştırma

9 Sorunlar ve öneriler

2 Veri setleri ve el hareketleri

4 Öznitelik seçimi ve anlamları

6 Değerlendirme yöntemi

8 Cylindrical etkisi & sınıf analizi

10 Sonuç

Neden EMG ile El Hareketi Tanıma?

EMG (elektromiyografi), kas kasıldığında üretilen elektriksel aktiviteyi ölçer. Ön koldaki yüzey sinyallerinden hangi hareketin yapıldığını çözmek; protez, rehabilitasyon ve insan–makine arayüzleri için kritik bir problemidir.



Protez el kontrolü

Ampute bireyler için doğal kontrol



Rehabilitasyon

Kas aktivasyonu takibi ve terapi



İnsan–makine arayüzü

Dokunmadan komut / etkileşim

TEMEL ZORLUK

Sinyal kişiden kişiye, hatta denemeden denemeye değişir.

Benzer kavramalar (silindirik ↔ kapalı) çok yakın kas aktivasyonu üretir.

Bu yüzden öznitelik ve model seçimi belirleyicidir.


Yüzey EMG Sinyali Nedir?

Yüzey EMG (sEMG) elektrotları, ön kol kasları kasıldığında oluşan elektriksel aktiviteyi ölçer. Farklı hareketler farklı kas gruplarını etkinleştirir → ayırt edilebilir sinyal örüntüleri.

- Girişimsiz, gerçek zamanlı, düşük maliyetli
- Gürültülü; kişi ve denemeye göre değişken
- Ham dalga yüksek boyutlu → özniteliklerle özetlenir
- Zaman-uzay öznitelikleri ucuz ve etkilidir

TEMEL FİKİR

Ham dalgayı doğrudan modele vermek yerine, kısa pencerele bölüp kas aktivitesinin özet tanımlayıcılarını çıkarırız. Sınıflandırıcı bu tanımlayıcıları harekete eşler.



Çalışmanın İşlem Hattı

Amaç: iki veri setinde altı modeli, tek ve aynı boru hattıyla adil biçimde karşılaştırmak.



Her adım tüm modeller için sabit → farkların kaynağı yalnızca modelin kendisi.

İki Tamamlayıcı Veri Seti

NinaPro DB5

Açık kaynak kıyaslama veri tabanı

Kanal	8 (Myo kol bandı)
Denek	S1, S2, S5, S10
Hareket	7 sınıf
Örnekleme	200 → 1000 Hz
Öznitelik	32 boyut/pencere
Boyut	19.591 pencere

Özel Veri (Ecem & Selman)

Düşük maliyetli 2 kanallı kayıt

Kanal	2
Denek	Ecem, Selman
Hareket	5 sınıf
Örnekleme	1000 Hz
Öznitelik	8 boyut/pencere
Boyut	67.885 pencere

8
EMG kanalı

4
denek

7
hareket

19.591
pencere

Exercise A			Exercise B			Exercise C			Exercise D					
1	Index flexion		1	Thumb up		1	Large diameter grasp		16	Quadpod grasp		1	Flexion of the little finger	
2	Index extension		2	Extension of index and middle, flexion of the others		2	Small diameter grasp (power grip)		17	Lateral grasp		2	Flexion of the ring finger	
3	Middle flexion		3	Flexion of ring and little finger, extension of the others		3	Fixed hook grasp		18	Parallel extension grasp		3	Flexion of the middle finger	
4	Middle extension		4	Thumb opposing base of little finger		4	Index finger extension grasp		19	Extension type grasp		4	Flexion of the index finger	
5	Ring flexion		5	Abduction of all fingers		5	Medium wrap		20	Power disk grasp		5	Abduction of the thumb	
6	Ring extension		6	Fingers flexed together in fist		6	Ring grasp		21	Open a bottle with a tripod grasp		6	Flexion of the thumb	
7	Little finger flexion		7	Pointing index		7	Prismatic four fingers grasp		22	Turn a screw (grasp the screwdriver with a stick grasp)		7	Flexion of index and little finger	
8	Little finger extension		8	Adduction of extended fingers		8	Stick grasp		23	Cut something (grasp the knife with an index finger extension grasp)		8	Flexion of ring and middle finger	
9	Thumb adduction		9	Wrist supination (axis: middle finger)		9	Writing tripod grasp					9	Flexion of index finger and thumb	
10	Thumb abduction		10	Wrist pronation (axis: middle finger)		10	Power sphere grasp						Rest	
11	Thumb flexion		11	Wrist supination (axis: little finger)		11	Three finger sphere grasp							
12	Thumb extension		12	Wrist pronation (axis: little finger)		12	Precision sphere grasp							
			13	Wrist flexion		13	Tripod grasp							
			14	Wrist extension		14	Prismatic pinch grasp							
			15	Wrist radial deviation		15	Tip pinch grasp							
			16	Wrist ulnar deviation										
			17	Wrist extension with closed hand										

Özel Veri — Ecem & Selman

İki denekten, düşük maliyetli 2 kanallı bir kurulumla toplandı. Sinyaller hareket başına kanal bazında (ch1, ch2) dört .mat dosyasında saklanır.

2	2	5	67.885
EMG kanalı	denek	hareket	pencere

Sınırlama: Yalnız 2 kanal → benzer kavramaları ayırmak için uzamsal bilgi kısıtlı. İleride sonuç farklarının ana nedeni bu.

Hand Gestures Recognized (7 Movements)

1. B1: Thumb Up
2. B2: Scissors
3. B5: Open
4. B6: Closed
5. B7: Point
6. C5: Cylindrical
7. C14: Pinch

HAREKETLER

Seçilen El Hareketleri

NinaPro (7)

- Thumb up (B1)
- Scissors (B2)
- Open (B5)
- Closed (B6)
- Point (B7)
- Cylindrical (C5)
- Pinch (C14)

Özel Veri (5)

- point
- rock
- closed
- cylindrical — en çok karışan sınıf**
- open

Sinyal Ön İşleme — Parametreler

NinaPro

- Tekrarlar (repetition) seçilir
- 200 → 1000 Hz yükseltme ($\times 5$)
- Pencere: 150 örnek (150 ms)
- Adım: 30 örnek → %80 örtüşme
- Çıktı: 32-boyut CSV + ham (150 $\times$ 8) tensör

Özel Veri

- Onset: 40 ms pencerede ort.|genlik| > 435
- Başlangıçtan 150 ms pencereler
- Adım: 30 ms → %80 örtüşme
- 2 kanal $\times$ 4 öznitelik = 8
- Çıktı: custom_dataset.csv


'Pencere' (Window) Tam Olarak Ne?

Pencere, sürekli EMG sinyalinden kesilen kısa, sabit uzunlukta bir parçadır (bu çalışmada 150 ms). Modelin sınıflandırdığı en küçük birim tüm sinyal değil, tek bir penceredir.

- Her pencereden bir öznitelik vektörü (RMS/MAV/WL/SSC) çıkarılır
- Model her pencere için ayrı bir tahmin yapar → bir hareket birçok pencere üretir
- Kayan pencere: pencere sabit adımla ileri kaydırılır (adım 30 ms)
- Örtüşme %80: ardışık pencereler büyük ölçüde çakışır → daha çok örnek, zamanda süreklilik

KISACA

1 pencere = 1 öznitelik vektörü = 1 tahmin. Sınıflandırma bu küçük parçalar üzerinde yapılır; hareketin nihai kararı pencerelerin birleşiminden gelir.



Pencere genişliği 150 ms · adım 30 ms · örtüşme %80 (kayan, çakışan pencereler)

Neden 200 Hz → 1000 Hz'e Yükseltiyoruz?

NinaPro 200 Hz kaydedilmiştir; ön işlemede 5 katına (1000 Hz) yükseltilir. Amaç yeni sinyal bilgisi eklemek DEĞİL — üç pratik nedendir:

1

Yeterli örnek / pencere

200 Hz'de 150 ms = 30 örnek; 1000 Hz'de 150 örnek. Fark-tabanlı WL ve SSC çok daha kararlı olur.

2

Tek boru hattı

Özel veri zaten 1000 Hz ve 150-örnek pencere. Yükseltince aynı pencere + öznitelik kodu ikisine de uyar.

3

CNN girdi uzunluğu

1B CNN 150 uzunlukta ham girdi bekler; 30 örnek büyük çekirdekler (10, 5) için yetersizdir.

ÖNEMLİ UYARI

Yükseltme bir interpolasyondur — gerçek yeni bilgi veya frekans eklemes (200 Hz'in Nyquist sınırı 100 Hz; üstü zaten kayıptır). **Kazanç: daha kararlı öznitelik + iki veri setinde tutarlılık + CNN'e uygun girdi uzunluğu.**

Öznitelik Seçimi — Neden Zaman Uzayı?

- Çok düşük hesap maliyeti → gerçek zamanlı / gömülü protez için uygun
- Yüzey EMG'nin küçük kaymalarına ve gürültüsüne dayanıklı
- sEMG literatüründe hareket tanıma için köklü ve kanıtlanmış
- 150 örneklik pencereyi kanal başına 4 sayıya, az bilgi kaybıyla indirger
- Basit, veri-verimli sınıflandırıcıların yüksek doğruluğa ulaşmasını sağlar

SEÇİM İLKESİ

Dört öznitelik birbirini tamamlar: genlik (RMS, MAV), karmaşıklık (WL) ve frekans (SSC) — az fazlalıkla dört farklı bilgi. Frekans-uzayı öznitelikleri daha pahalı ve bu problemde gereksiz görüldü.

Öznitelikler I — RMS ve MAV

RMS

Root Mean Square

$$\text{RMS} = \sqrt{\left(\frac{1}{N} \sum x_i^2 \right)}$$

Sinyalin karekök-ortalama-kare değeri. Kasın ürettiği toplam gücü / enerjiyi temsil eder; kasılma ne kadar güçlüyse o kadar yüksektir.

MAV

Mean Absolute Value

$$\text{MAV} = \left(\frac{1}{N} \sum |x_i| \right)$$

Ortalama mutlak genlik. En klasik sEMG genlik göstergesidir; sinyalin yoğunluğunu / şiddetini yansıtır ve gürültüye RMS'ten biraz daha dayanıklıdır.

Öznitelikler II — WL ve SSC

WL

Waveform Length

$$WL = \sum |x_{i+1} - x_i|$$

Ardışık örnekler arası mutlak farkların toplamı — dalganın kümülatif uzunluğu. Sinyalin karmaşıklığını (genlik + frekans birleşimini) dolaylı olarak ölçer.

SSC

Slope Sign Changes

$$SSC = \sum [(x_i - x_{i-1})(x_i - x_{i+1}) < 0]$$

Eğim işaretinin kaç kez değiştiğini sayar (tepe/vadi sayısı). Sinyalin frekans içeriğini tahmin eder; yüksek frekans → daha çok işaret değişimi.

ÖZNİTELİKLER

Öznitelik Vektörü ve Boyut

Her pencere, her kanal için 4 öznitelikle temsil edilir. Vektör boyutu doğrudan kanal sayısına bağlıdır:

NinaPro

8 kanal $\times$ 4 öznitelik

= 32 boyut / pencere

Özel Veri

2 kanal $\times$ 4 öznitelik

= 8 boyut / pencere

Kolon adları: RMS_ch1, MAV_ch1, WL_ch1, SSC_ch1, ... + Label. Öznitelik hesapları tek bir ortak modülde (emg_common.py) tanımlıdır.

Karşılaştırılan Altı Model

SVM

RBF çekirdek

RF

100 ağaç topluluğu

MEET

OvO + Extra Trees

CNN

1B evrişimli ağ

KNN

k=5 komşu

MLP


1×128 sinir ağı

İki klasik (SVM, RF), bir topluluk-uzman (MEET), bir derin (CNN) ve iki temel model (KNN, MLP).

SVM Nasıl Çalışır?


SVM, iki sınıfı en geniş boşlukla (marj) ayıran karar sınırını arar.

- Doğrusal ayrılamayan veriyi RBF çekirdeği ile daha yüksek boyuta taşır
- Orada iki sınıfı ayıran en geniş marjlı düzlemi bulur
- Sınıra en yakın örnekler 'destek vektörleri'dir; sınırı onlar belirler
- Yeni örnek düzlemin hangi tarafında ise o sınıfa atanır



Random Forest Nasıl Çalışır?

- Karar ağacı: veriyi özniteliklere göre ardışık evet/hayır sorularıyla böler
- Random Forest: 100 farklı ağaç eğitir (her biri rastgele veri + rastgele öznitelik alt kümesiyle)
- Her ağaç bağımsız bir oy verir → oy çokluğu nihai sınıfı belirler
- Ağaçlar farklı olduğundan topluluk ortalaması varyansı düşürür, gürültüye dayanıklıdır




MEET Nasıl Çalışır?

MEET = Mixture of Experts Extra Trees. Çok sınıflı problemi ikili alt problemlere böler ve her sınıf çifti için özelleşmiş bir 'uzman' eğitir.

- Bire-Bir (One-vs-One): her sınıf çifti için bir ikili sınıflandırıcı $\rightarrow n(n-1)/2$ uzman (5 sınıf = 10 uzman)
- Her uzman yalnızca iki sınıfı ayırmaya odaklanır $\rightarrow$ o çift için çok keskin karar sınırı
- Uzmanların temeli Extra Trees (aşırı rastgele ağaçlar) $\rightarrow$ düşük varyans, hızlı eğitim
- Tahmin: yeni örnek tüm uzmanlara sorulur, oylar toplanır, en çok oyu alan sınıf kazanır

NE İŞE YARAR?

- Birbirine benzeyen zor çiftleri (silindirik $\leftrightarrow$ kapalı, B1 $\leftrightarrow$ B7) tek modele göre çok daha iyi ayırır
- Bu çalışmada en dengeli ve en yüksek doğruluğu verdi (NinaPro'da > %94)
- Uzmanlaşma + rastgelelik = keskin sınır + düşük varyans



MEET — Ayrıntı: Fikir, Mimari ve Uygulama

Temel fikir (Gehlot ve ark., 2024): tek bir modelle tüm sınıfları ayırmak yerine, her biri küçük bir sınıf alt kümesine uzmanlaşmış Extra Trees 'uzmanları' kullanmak.

MAKALEDEKİ MİMARİ (Gehlot 2024)

- N sınıf için $\sim N/2$ uzman + 1 'kapı (gate)' sınıflandırıcı
- Her uzman bir sınıf çiftini öğrenir (E1: sınıf 1–2, E2: 3–4, ...)
- Kapı, tüm veriyle eğitilir ve uzman çıktılarını ağırlıklandırır
- Nihai çıktı = uzmanların ağırlıklı birleşimi


BU ÇALIŞMADAKİ UYGULAMA

- scikit-learn OneVsOne + Extra Trees
- Her sınıf çifti için bir ikili Extra Trees uzmanı (5 sınıf = 10 uzman)
- Tahmin: oy çokluğu
- Makaledeki 'uzmanlaşma' fikrinin pratik bir uyarlaması

NEDEN GÜÇLÜ? Her uzman yalnızca birkaç sınıfa odaklandığından silindirik↔kapalı gibi zor çiftleri keskin ayırır → en dengeli ve en yüksek doğruluk (NinaPro > %94).


KNN Nasıl Çalışır?

- Eğitim yoktur; tüm örnekler bellekte saklanır
- Yeni bir örnek gelince tüm örneklere uzaklık hesaplanır
- En yakın $k = 5$ komşu seçilir
- Bu 5 komşunun oy çokluğu tahmini verir




MLP (Sinir Ağı) Nasıl Çalışır?

- Girdi: öznitelik değerleri (custom'da 8)
- Gizli katman: her nöron ağırlıklı toplam + ReLU aktivasyonu
- Çıktı katmanı: softmax ile sınıf olasılıkları
- Öğrenme: geri yayılım (backprop) ile ağırlıklar güncellenir



1B CNN Nasıl Çalışır?

- Evrişim (conv) filtreleri girdinin üzerinde kayarak yerel örüntüleri yakalar
- ReLU + havuzlama (pooling): boyutu küçültür, önemli sinyali korur
- Düzleştirme sonrası tam bağlı (Dense) katman sınıflandırır; filtreler eğitimle öğrenilir



Ham/öznitelik girdisi → yerel örüntü çıkarımı → boyut indirgeme → sınıflandırma

SVM — Destek Vektör Makinesi

SVM (RBF)

SEÇİLEN PARAMETRELER

kernel	RBF (radyal)
C	10
gamma	'scale'
random_state	22

NEDEN BU SEÇİM?

- RBF çekirdek: EMG öznitelik uzayı doğrusal ayrılabilir değil
→ doğrusal olmayan sınır gerekir
- C=10: marj genişliği ile hata cezası dengesi; sEMG'de genelde iyi sonuç veren orta-yüksek değer
- gamma='scale': çekirdek genişliğini öznitelik varyansına göre otomatik ayarlar
- Ölçekleme şart: SVM uzaklık temelli olduğu için standardizasyona duyarlı

Random Forest — Rastgele Orman

Random Forest

SEÇİLEN PARAMETRELER

n_estimators	100
max_depth	None
n_jobs	-1
random_state	22

NEDEN BU SEÇİM?

- 100 ağaç: kararlı topluluk için yeterli; daha fazlası marjinal katkı, daha çok hesap
- max_depth=None: ağaçlar tam büyür, topluluk ortalaması aşırı-öğrenmeyi dengeler
- Bagging + rastgele öznitelik → düşük varyans, gürültüye dayanıklı
- Öznitelik önemini de verir; yorumlanabilirlik avantajı

MEET — Mixture of Experts Extra Trees

MEET (OvO + Extra Trees)

SEÇİLEN PARAMETRELER

strateji	OneVsOne
temel öğrenici	ExtraTrees
n_estimators	100
random_state	22

NEDEN BU SEÇİM?

- OvO: her hareket çifti için ayrı bir 'uzman' → $n(n-1)/2$ ikili sınıflandırıcı
- Zor çiftleri (B1↔B7, C5↔C14) tek modele göre daha keskin ayırır
- Extra Trees: aşırı rastgele ağaçlar → daha düşük varyans, hızlı
- Gehlot ve ark. (2024) makalesinden uyarlandı

KNN — k-En Yakın Komşu

KNN (k=5)

SEÇİLEN PARAMETRELER

n_neighbors (k)	5
metric	Öklid
eğitim	yok (tembel)
ölçekleme	zorunlu

NEDEN BU SEÇİM?

- k=5: tek sayı (eşitlik olmaz), yerel yapıyı yakalayacak kadar küçük
- Öklid uzaklık: standartlaştırılmış özniteliklerde en yakın 5 komşunun oyu
- Eğitim yok — tüm hesap tahmin anında; basit ve yorumlanabilir
- Dezavantaj: sınıf örtüşmesine ve gürültüye duyarlı, bellek/tahmin maliyeti yüksek

MLP — Çok Katmanlı Algılayıcı

MLP (1×128)

SEÇİLEN PARAMETRELER

gizli katman	(128,) ReLU
çıktı	softmax
çözücü	Adam, lr=0.001
max_iter	300 · seed 22

NEDEN BU SEÇİM?

- Tek gizli katman, 128 nöron: küçük öznitelik uzayı için yeterli kapasite
- ReLU aktivasyon + softmax çıktı → çok sınıflı olasılık
- Adam optimizasyon: uyarlanabilir öğrenme oranı, hızlı yakınsama
- Doğrusal olmayan karar sınırları öğrenir; standartlaştırılmış girdi şart

1B CNN — İki Mimari

NinaPro CNN (ham 150×8)

- 2× Conv1D (64/128) + BatchNorm + MaxPool
- Büyük çekirdek (10,5) → zamansal örüntü
- Dense(256/128)+Dropout, çıktı softmax(7)

Özel Veri CNN (8 öznitelik)

- Conv1D(32,3) + MaxPool
- Dense(64)+Dropout, çıktı softmax(6)
- Zaman eksenini yok → minik ağ yeterli

Ortak eğitim: Adam (lr=0.001), sparse categorical crossentropy, erken durdurma (en iyi ağırlık geri yükleme), ReduceLROnPlateau, dengeli sınıf ağırlığı, seed 22.

Değerlendirme Yöntemi

1 %80 / %20 bölme

Sınıf dağılımını koruyan (stratified) ayırım

2 Ölçekleme yalnız eğitimde

StandardScaler sadece eğitimde 'fit' → veri sızıntısı yok

3 Denek-içi & denekler-arası

Aynı denekler / hiç görülmemiş denekler (S1, S10)

4 Sabit tohum (22)

Tüm modellerde tekrarlanabilirlik


5 Metrikler

Doğruluk, precision/recall/F1, normalize confusion matrix

SONUÇLAR


Sonuçlar — NinaPro (6 Model)

MEET	%94,74
Random Forest	%92,88
SVM (RBF)	%87,65
MLP (1×128)	%86,35
KNN (k=5)	%86,06
1B CNN (ham)	~%82,7



MEET — neredeyse tüm sınıflarda > %92

NinaPro — Detaylı Karşılaştırma



YORUM


- RF ve MEET (topluluk/uzman) açık ara en iyi
- SVM $\approx$ MLP $\approx$ KNN orta grup ($\sim$ %86-88)
- CNN en geride ($\sim$ %83)
- İyi öznitelikler klasik modelleri güçlü kılıyor

NinaPro — Sınıf Bazlı Doğruluk


Sınıf	SVM	RF	MEET	KNN	MLP
Thumb up (B1)	87,4	93,9	96,7	92,2	91,9
Scissors (B2)	86,2	91,9	92,7	89,2	85,9
Open (B5)	90,2	94,6	94,8	88,9	86,2
Closed (B6)	88,3	89,9	92,6	86,3	83,3
Point (B7)	87,0	92,0	95,1	77,0	80,8
Cylindrical (C5)	84,4	90,4	93,1	82,0	85,4
Pinch (C14)	90,2	96,8	97,4	86,4	89,3

Değerler % doğruluk (recall). MEET her sınıfta lider; KNN'in en zayıfı Point (%77).

NinaPro — KNN ve MLP Matrisleri



KNN — Point/B7 en zayıf (%77)




MLP — daha dengeli profil

Sonuçlar — Özel Veri (5 sınıf · tip yok)

Tüm modeller ~%70–73 bandında; KNN en zayıf (%70). Ortak darboğaz **silindirik ↔ kapalı**.

Random Forest	%72,98
MLP (1×128)	%72,92
SVM (RBF)	%72,75
1B CNN	%72,62
MEET	%72,46
KNN (k=5)	%69,68




Cylindrical'ı Çıkarınca — Etki

Silindirik (tek ayrılamayan sınıf) çıkarıldığında (4 sınıf) tüm modeller belirgin iyileşir. En büyük kazanç 'kapalı' sınıfında:

Model	5 sınıf (cyl dahil)	4 sınıf (cyl hariç)	Değişim
KNN (k=5)	%69,68	%81,50	+11,8
MLP (1×128)	%72,92	%83,21	+10,3
1B CNN	%72,62	%82,96	+10,3
SVM / RF / MEET	~%73	~%83	~+10

'**kapalı**' sınıfı: KNN %72,5 → %89,4 · MLP %74,4 → %91,4 · CNN %69,3 → %91,7 (SVM/RF/MEET'te de closed ~%92). Sebep modeller değil, 2 kanalla silindirik–kapalı ayrımının yapılamamasıdır.

Özel Veri — 6 Model Karşılaştırması (cyl dahil)



YORUM


- Altı model de ~%70–73 bandında sıkışıyor
- CNN de (%72,6) klasiklerle başa baş
- KNN en düşük (%70) — örtüşmeye kırılgan
- Ortak darboğaz: silindirik ↔ kapalı

Özel Veri — Sınıf Bazlı Doğruluk (cyl dahil)

Hareket	SVM	RF	MEET	KNN	MLP	CNN
point	68,4	68,5	69,1	68,6	67,4	71,5
rock	80,9	82,2	81,3	78,5	82,5	80,6
closed	73,9	74,3	75,6	72,5	74,4	69,3
cylindrical	59,2	57,4	55,2	50,9	58,2	60,7
open	81,4	82,5	81,1	77,9	82,1	81,1

Silindirik satırı altı modelin tamamında en düşük (~%51-61) — asıl darboğaz.


Özel Veri — cyl Dahil vs Hariç




SİLİNDİRİK ÇIKINCA

- KNN: %69,7 → %81,5 (+11,8)
- MLP: %72,9 → %83,2 (+10,3)
- CNN: %72,6 → %83,0 (+10,3)
- 'closed': KNN %73 → %89, MLP/CNN %74 → %92
- Klasik (SVM/RF/MEET) de ~%73 → ~%83

Özel Veri — KNN ve MLP Matrisleri (cyl dahil)




KNN — silindirik %50,9




MLP — silindirik %58,2

Özel Veri — KNN ve MLP Matrisleri (cyl hariç)



KNN — 'closed' %89,4'e çıkıyor



MLP — 'closed' %91,4'e çıkıyor

Karşılaştırmalı Analiz

Neden NinaPro » Özel veri?

8 kanal, benzer kavramaları ayırmak için gereken uzamsal çözünürlüğü sağlar; 2 kanal sağlayamaz.

Neden MEET / RF en iyi?

Topluluk ve Bire-Bir uzman yapıları zor çiftleri keskin ayırır ve varyansı düşürür.

MLP vs KNN?

MLP esnek karar sınırıyla klasiklerle yarışır; KNN mesafe-tabanlı olduğu için örtüşmeye en kırılgan.

Neden CNN geride?

Bu veri hacminde el yapımı öznitelikler zaten güçlü; CNN'in ham sinyal avantajı sınırlı.


Sorunlar ve Geliştirme Önerileri

Karşılaşılan Sorunlar

- Silindirik $\rightarrow$ kapalı karışması (ana darboğaz)
- 2 kanalın uzamsal bilgi sınırı
- Tekrarlanabilirlik: tohum tutarsızlığı (düzeltildi)
- Kod tekrarı $\rightarrow$ ortak modülde toplandı

Öneriler

- Kanal sayısını artır (en yüksek getiri)
- Daha fazla denek $\rightarrow$ genelleme
- Frekans-uzayı öznitelikleri ekle
- k-kat çapraz doğrulama
- MLP mimari / KNN uzaklık-ağırlık taraması



SONUÇ

**Altı model içinde MEET ve Random Forest,
8 kanallı sEMG'de en iyisi (> %92)**

İyi tasarlanmış zaman-uzayı öznitelikleri klasik modelleri güçlü kılıyor; MLP rekabetçi, KNN en temel yaklaşım. Özel verideki tavan model değil, 2 kanalın fiziksel sınırındır — en yüksek getirili adım kanal sayısını artırmaktır.



Teşekkürler • Sorular?

Kaynaklar

1. **MEET modeli** — Gehlot, N., Jena, A., Kumar, R., Bukya, M. (2024). MEET: Mixture of Experts Extra Tree-Based sEMG Hand Gesture Identification. arXiv:2405.09562.
2. **NinaPro veri tabanı** — Atzori, M. et al. (2014). Electromyography data for non-invasive naturally-controlled robotic hand prostheses. Scientific Data 1:140053. — ninapro.hevs.ch
3. **NinaPro DB5** — Pizzolato, S. et al. (2017). Comparison of six EMG acquisition setups on hand movement classification tasks. PLoS ONE 12(10):e0186132.
4. **Zaman-uzayı öznitelikleri (RMS/MAV/WL/SSC)** — Hudgins, B., Parker, P., Scott, R. N. (1993). A new strategy for multifunction myoelectric control. IEEE Trans. Biomed. Eng. 40(1):82–94.
5. **Random Forest** — Breiman, L. (2001). Random Forests. Machine Learning 45(1):5–32.
6. **Extra Trees** — Geurts, P., Ernst, D., Wehenkel, L. (2006). Extremely randomized trees. Machine Learning 63(1):3–42.
7. **scikit-learn (SVM, RF, ET, KNN, MLP)** — Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. JMLR 12:2825–2830.